Aula 13:
Computação Evolutiva e Conexionista – Particle Swarm Optimization – PSO

Prof. Hugo Puertas de Araújo
hugo.puertas@ufabc.edu.br
Sala: 509.2 (5º andar / Torre 2)

Agenda

- Particle Swarm Optimization – PSO
- Comparação com outras heurísticas

Computação Evolutiva e Conexionista

Particle Swarm Optimization

Particle Swarm Optimization

- PSO pode ser visto como uma simulação de um bando de pássaros (peixes, etc.) procurando por alimento.
- A comunicação entre cada pássaro é realizada tão somente por pequenos ajustes na trajetória e velocidade de voo: um pássaro avista o alimento e ajusta sua trajetória; em resposta, o resto do bando também atualiza o seu voo.
- O mesmo se dá no PSO: as partículas se comunicam ajustando suas posições e velocidades.
- A **posição de cada partícula** representa uma **solução potencial** para o problema de otimização, e as partículas “exploram” o espaço de busca voando através dele.

PSO – Vantagens

- É um algoritmo de otimização simples, fácil de entender e implementar.
- Não requer informação de gradiente, tornando-o adequado para funções objetivo não diferenciáveis e descontínuas.
- Ele pode pesquisar ‘todo’ o espaço de soluções e encontrar várias soluções em uma única execução.
- Tem a capacidade de escapar dos ótimos locais devido à sua natureza estocástica.
- Ele pode ser usado em uma ampla gama de aplicações, incluindo problemas de otimização em engenharia, finanças e saúde.

PSO – Vantagens

- O PSO é ideal para:
  - Problemas contínuos: Onde as soluções podem ser representadas como vetores de números reais.
    - Exemplo: Ajuste de parâmetros em redes neurais.
  - Otimização multidimensional: Especialmente em espaços de alta dimensionalidade.
  - Problemas onde gradientes não estão disponíveis: O PSO não depende de derivadas da função objetivo.
  - Problemas com superfícies suaves: Onde a função objetivo não apresenta muitos mínimos locais.

PSO – Desvantagens

- Não é garantido encontrar o ótimo global e pode convergir para um ótimo local.
- O desempenho do PSO depende muito da seleção dos parâmetros do algoritmo, o que pode ser demorado e exigir muita experimentação.
- O PSO pode sofrer de convergência prematura, que ocorre quando as partículas convergem muito rapidamente para uma solução subótima.
- Pode ser computacionalmente caro, especialmente para problemas de alta dimensão com um grande número de partículas.
- Pode ser sensível ao ruído na função objetivo, o que pode levar a resultados imprecisos.

PSO – Desvantagens

- O PSO é menos eficaz em:
  - Problemas combinatórios: Como o problema do caixeiro-viajante (TSP), onde representações discretas são necessárias.
  - Problemas com muitos mínimos locais profundos: A tendência de convergência pode levar ao aprisionamento em ótimos locais.
  - Problemas de alta complexidade de restrições: Como otimização com restrições não lineares.
  - Problemas discretos: O PSO lida melhor com valores contínuos do que inteiros ou binários.

PSO – Passo a passo

1. Inicialização: Defina o domínio do problema e inicialize a população de partículas (soluções candidatas) aleatoriamente dentro do domínio.
2. Avaliação: Avalie a aptidão de cada partícula (com base em sua posição).
3. Atualizar o recorde pessoal: atualize a melhor posição pessoal de cada partícula com base em seu valor de aptidão.
4. Atualizar o melhor global: Atualize a melhor posição global com base na melhor posição de todas as partículas.
5. Atualizar velocidade e posição: atualize a velocidade e a posição de cada partícula com base em sua posição e velocidade atuais e nas melhores posições pessoais e globais.
6. Término: Repita as etapas 2 a 5 para um número fixo de iterações ou até que um critério de parada seja atendido (por exemplo, número máximo de iterações alcançado, valor de aptidão alvo alcançado, etc.).

PSO – Regras

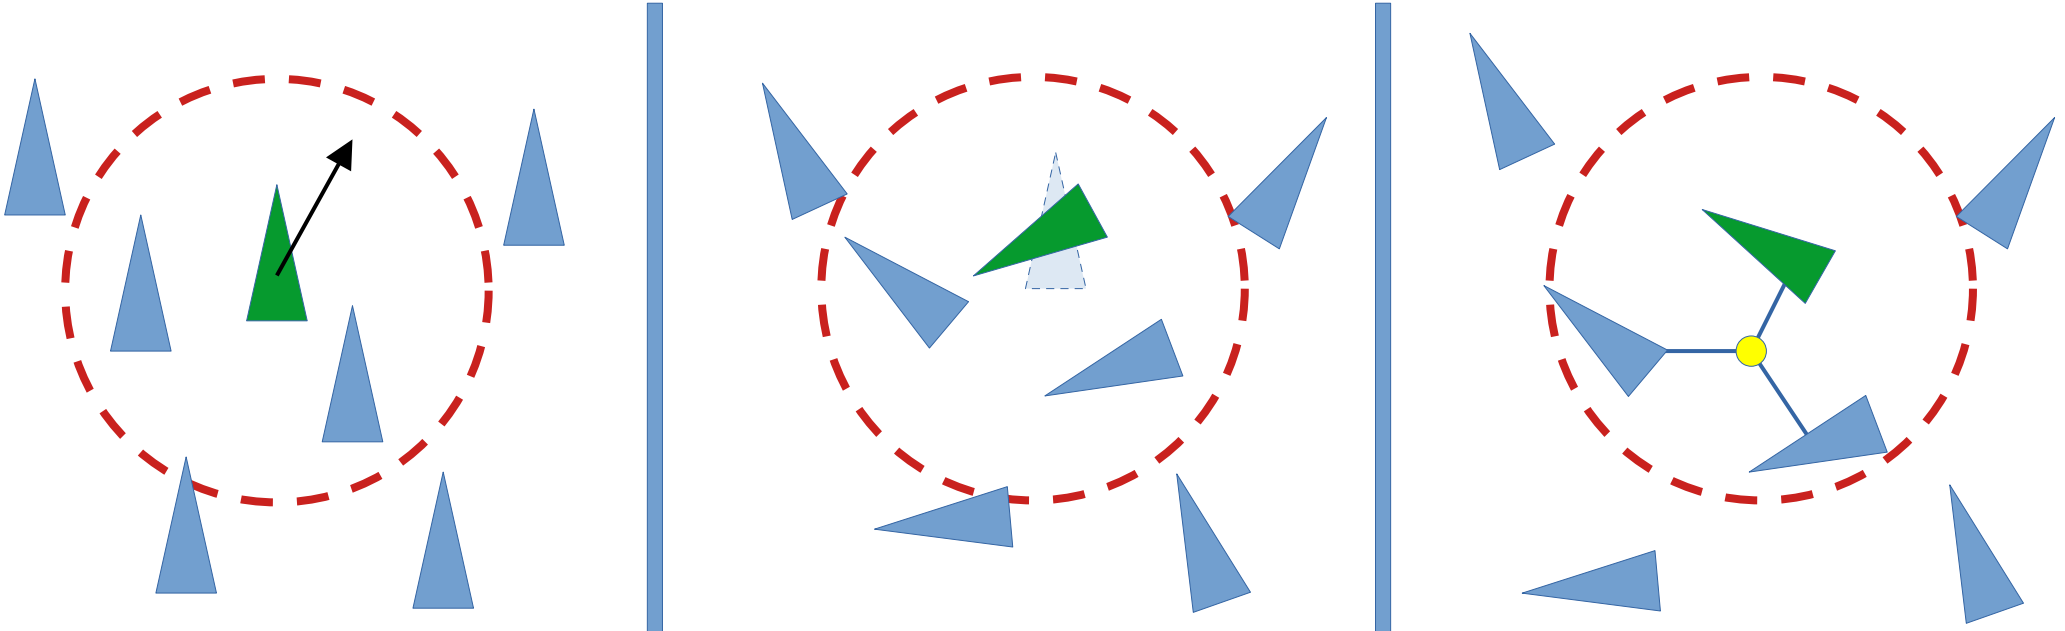

Afastamento

Alinhamento

Coesão

CMCC
Centro de Matemática, Computação e Cognição

PSO – Equações

$$X^i(t) = (x^i(t), y^i(t))$$

$$X^i(t+1) = X^i(t) + V^i(t+1)$$

Exploração

Explotação

$$V^i(t+1) = \omega V^i(t) + \alpha(local^i - X^i(t)) + \beta(global - X^i(t))$$

$$\alpha = c_1 r_1$$

$$\beta = c_2 r_2$$

Inércia

CMCC
Centro de Matemática, Computação e Cognição

PSO – Equações

The parameter W is the inertia weight and it is a positive constant, This parameter is important for balancing the global search, also known as **exploration** (when higher values are set), and local search, known as **exploitation** (when lower values are set).

Diversification: searches new solutions, finds the regions with potentially the best solutions.

Intensification: explores the previous solutions, finds the best solution of a given region.

$$V_i^{t+1} = W.V_i^t + c_1 U_1^t \left(P_{b_1}^t - P_i^t\right) + c_2 U_2^t \left(g_b^t - P_i^t\right)$$

Inertia : Makes the particle move in the same direction and with the same velocity.

Personal Influence : Improves the individual. Makes the particle return to a previous position, better than the current.

Social Influence : Makes the particle follow the best neighbors direction.

PSO – Exploração x Explotação

Tende a explorar bem no início e refinar (explorar localmente) posteriormente.

PSO – Visualização

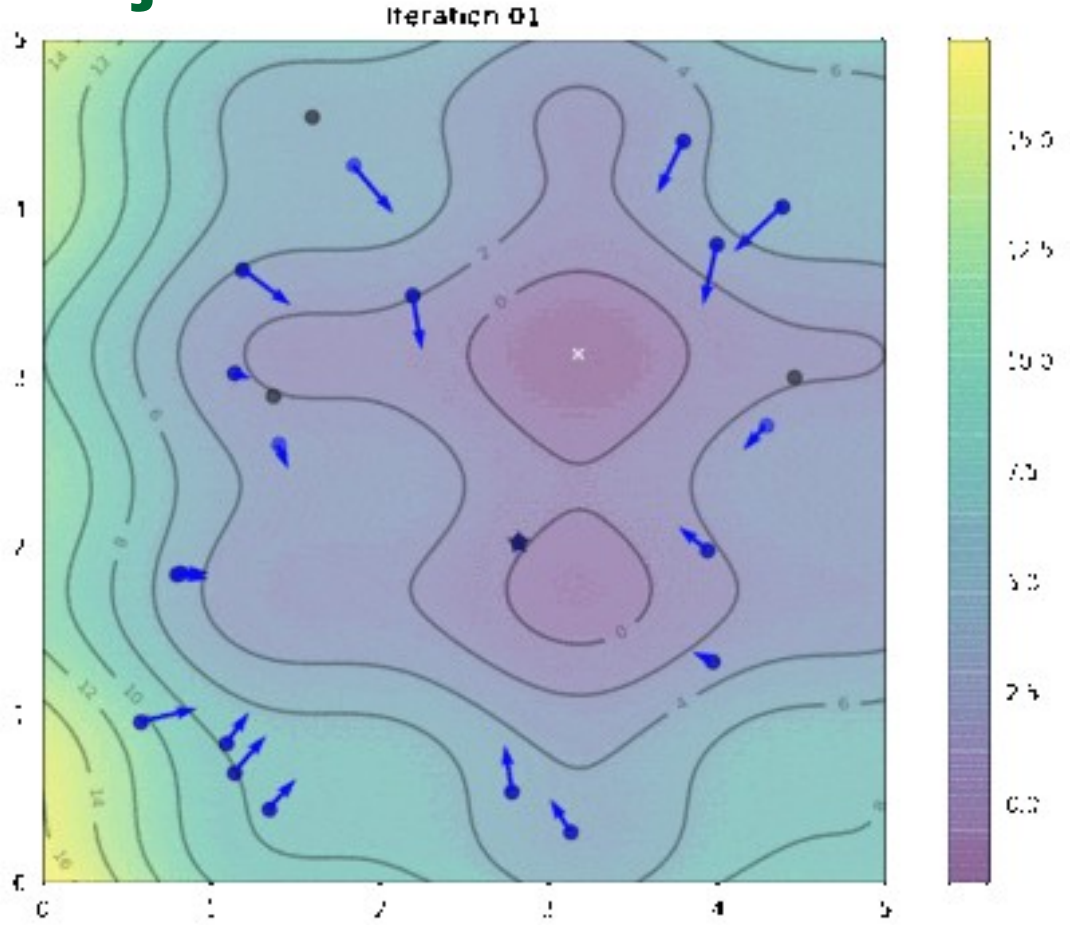

https://www.macs.hw.ac.uk/~dwcorne/mypages/apps/pso.html

CMCC
Centro de Matemática, Computação e Cognição

PSO – Comparação c/outras heurísticas

Critério	PSO	GA
Inspiração	Comportamento de enxames (pássaros/peixes).	Evolução biológica (seleção natural).
Representação	Partículas como soluções no espaço contínuo.	Cromossomos representando soluções (binários, reais ou outros).
Operadores	Atualização de posição e velocidade.	Seleção, crossover e mutação.
Exploração e Explotação	Melhor para refinar soluções localmente após encontrar regiões promissoras.	Melhor para explorar amplamente o espaço de busca.
Velocidade de Convergência	Geralmente mais rápido em problemas contínuos.	Pode ser mais lento devido à recombinação genética.
Robustez em Mínimos Locais	Propenso a convergir em mínimos locais.	Melhor para escapar de mínimos locais devido à variabilidade genética.
Melhor Caso de Uso	Otimização contínua de funções e ajustes de parâmetros.	Problemas combinatórios ou discretos (como roteamento).
Pior Caso de Uso	Problemas combinatórios ou com muitas restrições.	Funções contínuas altamente correlacionadas.
Forças	Simplicidade, eficiência em espaços contínuos de alta dimensionalidade.	Capacidade de explorar globalmente e escapar de mínimos locais.
Fraquezas	Tendência à convergência prematura.	Operações podem ser computacionalmente mais caras.

PSO – Comparação c/outras heurísticas

Critério	PSO	ACO
Inspiração	Comportamento de enxames (pássaros/peixes).	Comportamento de formigas buscando comida.
Representação	Partículas como vetores em um espaço contínuo.	Caminhos representados como grafos.
Estratégia de Busca	Atualização iterativa de posição e velocidade.	Reforço iterativo de trilhas de feromônio.
Exploração e Explotação	Melhor para problemas contínuos de alta dimensionalidade.	Melhor equilíbrio em problemas discretos e grafos.
Velocidade de Convergência	Geralmente mais rápido em espaços contínuos.	Pode ser mais lento devido ao reforço progressivo das trilhas.
Robustez em Mínimos Locais	Pode se prender em mínimos locais profundos.	Melhor para escapar de mínimos locais devido à estocasticidade.
Melhor Caso de Uso	Otimização de funções contínuas e ajustamento de parâmetros.	Problemas de grafos como TSP e roteamento.
Pior Caso de Uso	Problemas discretos com representações de grafos.	Problemas contínuos de alta dimensionalidade.
Forças	Simples, eficaz em funções contínuas.	Alta eficiência em problemas de grafos e roteamento.
Fraquezas	Ineficaz em problemas combinatórios.	Maior custo computacional em espaços contínuos.

PSO – Comparação c/outras heurísticas

Critério	PSO	ABC
Inspiração	Comportamento de enxames (pássaros/peixes).	Busca cooperativa de abelhas por alimentos.
Representação	Partículas representando soluções contínuas.	Abelhas como agentes explorando o espaço de busca.
Estratégia de Busca	Ajuste de posição e velocidade no espaço de busca.	Divisão de trabalho entre exploração, explotação e compartilhamento.
Exploração e Explotação	Melhor para problemas contínuos e suaves.	Melhor para problemas amplos e pouco conhecidos.
Velocidade de Convergência	Rápido em problemas bem definidos.	Pode ser mais lento devido ao balanceamento de fases.
Robustez em Mínimos Locais	Tende a convergir prematuramente.	Melhor em evitar mínimos locais devido à diversidade de agentes.
Melhor Caso de Uso	Otimização de funções contínuas.	Problemas com grande espaço de busca e sem informações prévias.
Pior Caso de Uso	Problemas discretos ou com muitos mínimos locais.	Problemas que exigem rápida convergência.
Forças	Simplicidade, boa exploração inicial em espaços contínuos.	Resiliência em mínimos locais, forte equilíbrio entre exploração e explotação.
Fraquezas	Limitações em problemas discretos ou combinatórios.	Pode ser computacionalmente mais caro para problemas simples.

PSO – Comparação c/ outras heurísticas

Algoritmo	Melhor Caso	Pior Caso	Forças	Fraquezas
PSO	Problemas contínuos de alta dimensionalidade.	Problemas discretos ou combinatórios.	Simplicidade, velocidade e eficiência.	Propenso a convergência prematura.
GA	Problemas combinatórios e discretos.	Funções contínuas altamente correlacionadas.	Boa exploração global.	Operações genéticas mais lentas.
ACO	Problemas de grafos e roteamento.	Problemas contínuos complexos.	Excelente em problemas discretos.	Lento em certos cenários.
ABC	Espaços amplos e pouco explorados.	Problemas que exigem alta velocidade de convergência.	Resiliência contra mínimos locais.	Custo computacional maior em alguns casos.