Redes associativas matriciais com aprendizado *Hebbiano*

Revisar o capitulo 4 do livro: Explorations in PDP utilizando o custom GPT do chatGPT:

(Procurar: Tudo sobre o livro "Explorations in PDP")

Aprendizado de Hebb

- *“Quando um axónio de uma célula A está perto suficiente de una célula B, como para excita-la, e participa repetida o persistentemente no seu disparo, acontece algum processo de crescimento ou mudança metabólica, em uma o em ambas células, de tal modo que a eficiência de A disparando sobre B aumenta…”*

Modelos artificiais de plasticidade sináptica

1. Modelo de Hebb

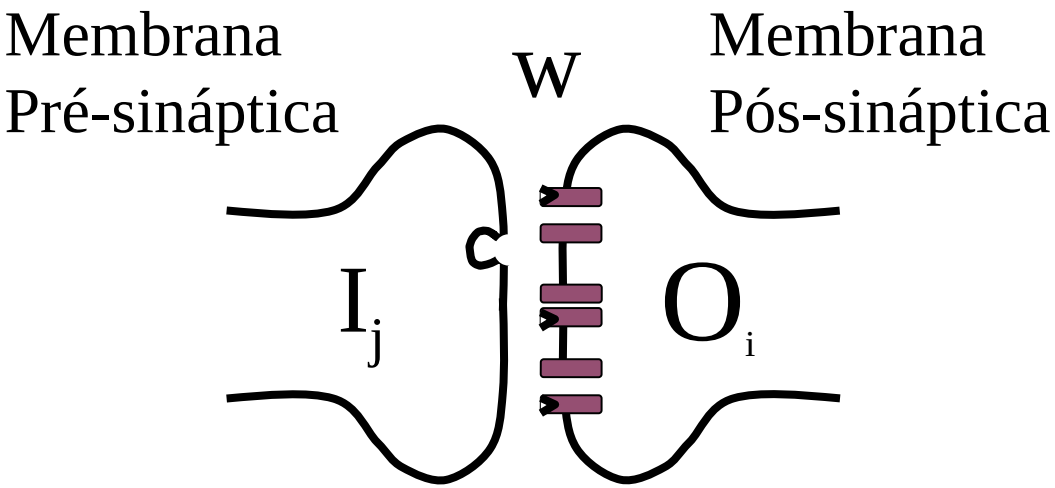

Fator de aprendizado

$$\Delta w_{ij} = \xi O_i I_j$$

$$\xi = 0{,}1$$

w_{ij}	I_j	O_i	Δw_{ij}
0	1	1	

Neste exemplo colocam-se valores arbitrários de I_j e Oi em cada instante

Modelos artificiais de plasticidade sináptica

1. Modelo de Hebb

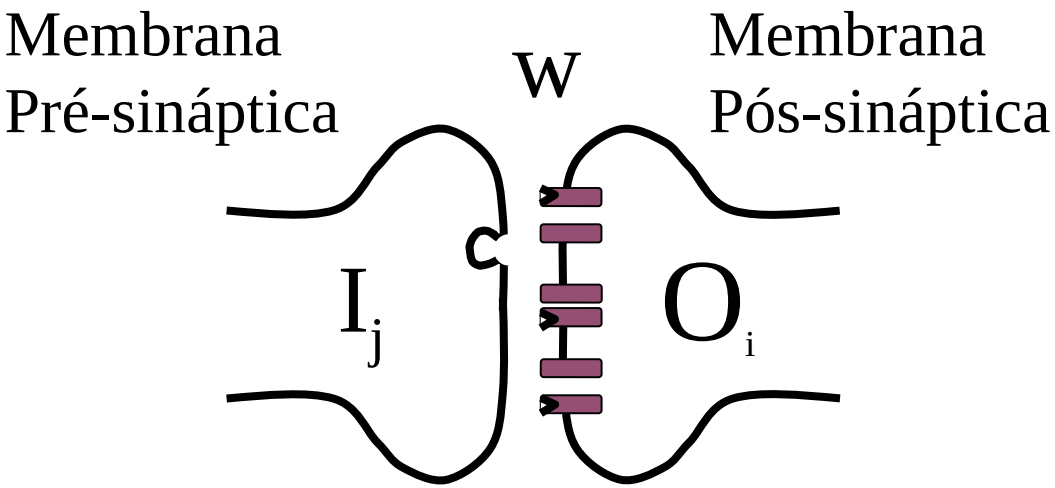

Fator de aprendizado

$$\Delta w_{ij} = \xi O_i I_j$$

$$\xi = 0{,}1$$

w_{ij}	I_j	O_i	Δw_{ij}
0	1	1	0,1
0,1			

Neste exemplo colocam-se valores arbitrários de I_j e Oi em cada instante

Modelos artificiais de plasticidade sináptica

1. Modelo de Hebb

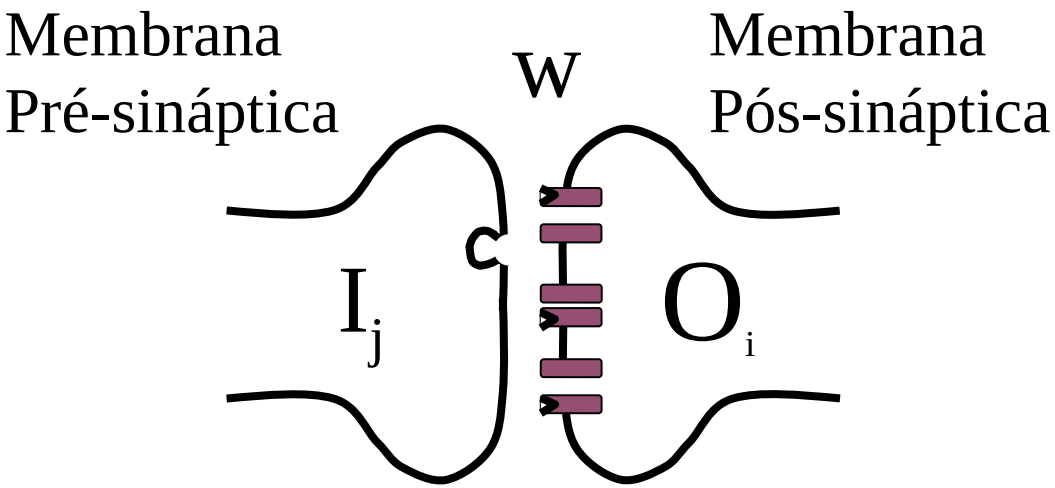

Fator de aprendizado

$$\Delta w_{ij} = \xi O_i I_j$$

$$\xi = 0{,}1$$

w_{ij}	I_j	O_i	Δw_{ij}
0	1	1	0,1
0,1	1	0,5	

Neste exemplo colocam-se valores arbitrários de I_j e Oi em cada instante

Modelos artificiais de plasticidade sináptica

1. Modelo de Hebb

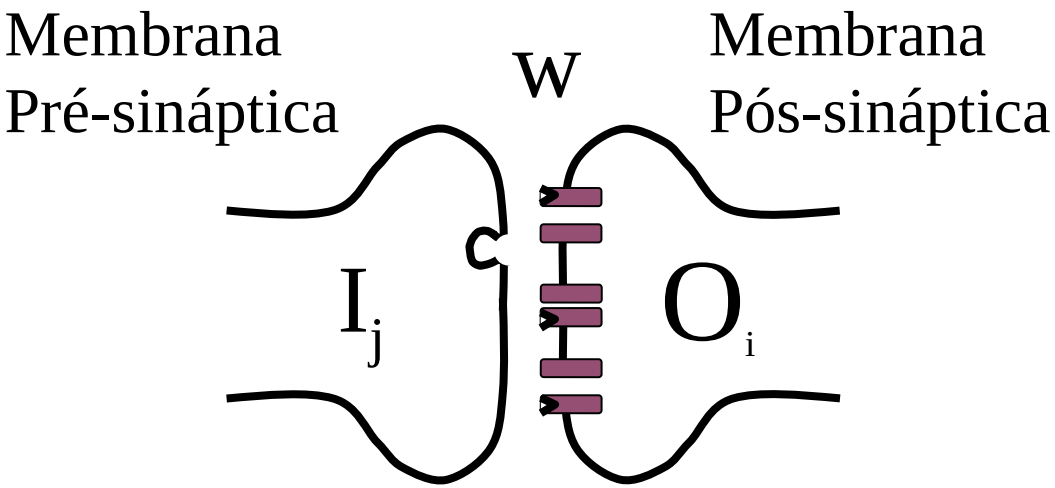

Fator de aprendizado

$$\Delta w_{ij} = \xi O_i I_j$$

$$\xi = 0{,}1$$

w_{ij}	I_j	O_i	Δw_{ij}
0	1	1	0,1
0,1	1	0,5	0,05
0,15			

Neste exemplo colocam-se valores arbitrários de I_j e Oi em cada instante

Modelos artificiais de plasticidade sináptica

1. Modelo de Hebb

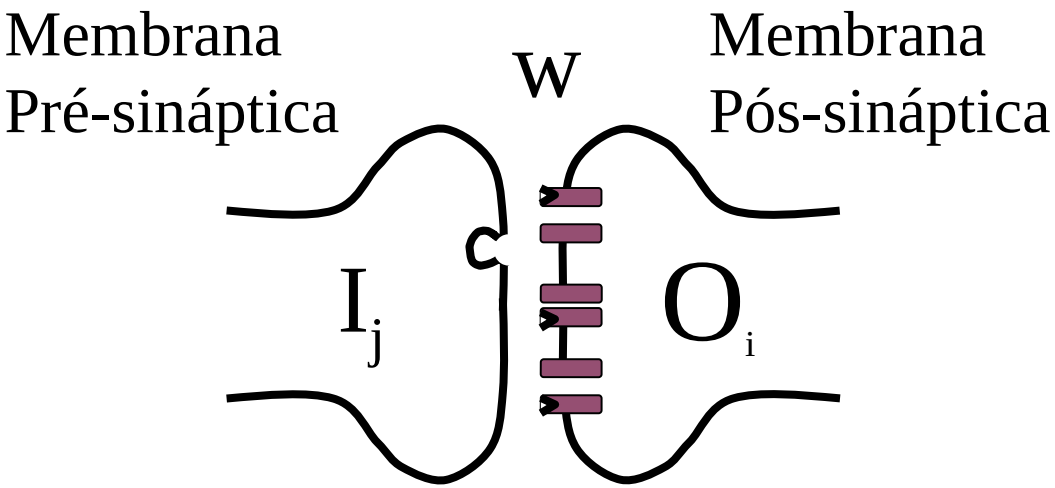

Fator de aprendizado

$$\Delta w_{ij} = \xi O_i I_j$$

$$\xi = 0{,}1$$

w_{ij}	I_j	O_i	Δw_{ij}
0	1	1	0,1
0,1	1	0,5	0,05
0,15	0,1	0,5	

Neste exemplo colocam-se valores arbitrários de I_j e Oi em cada instante

Modelos artificiais de plasticidade sináptica

1. Modelo de Hebb

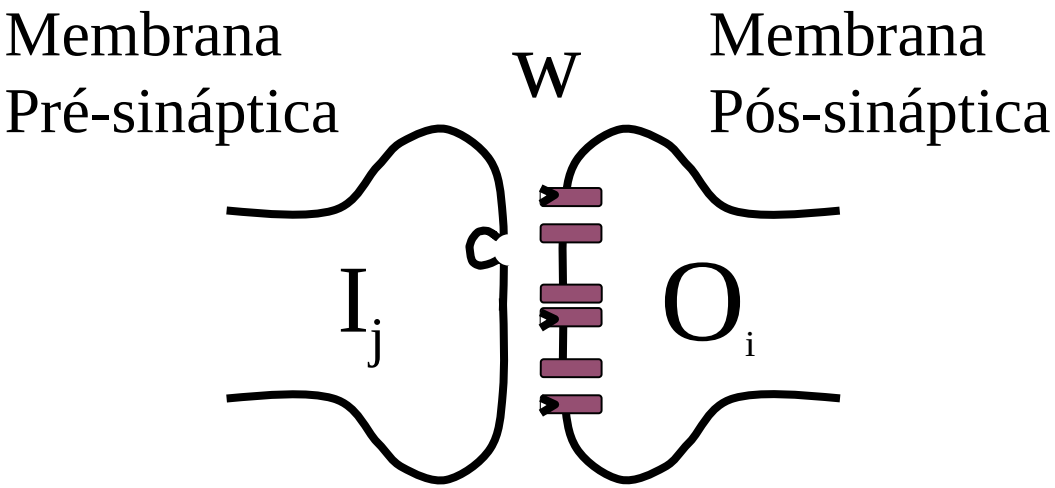

Fator de aprendizado

$$\Delta w_{ij} = \xi O_i I_j$$

$$\xi = 0{,}1$$

w_{ij}	I_j	O_i	Δw_{ij}
0	1	1	0,1
0,1	1	0,5	0,05
0,15	0,1	0,5	0,005
0,155			

Neste exemplo colocam-se valores arbitrários de I_j e Oi em cada instante

Modelos artificiais de plasticidade sináptica

1. Modelo de Hebb

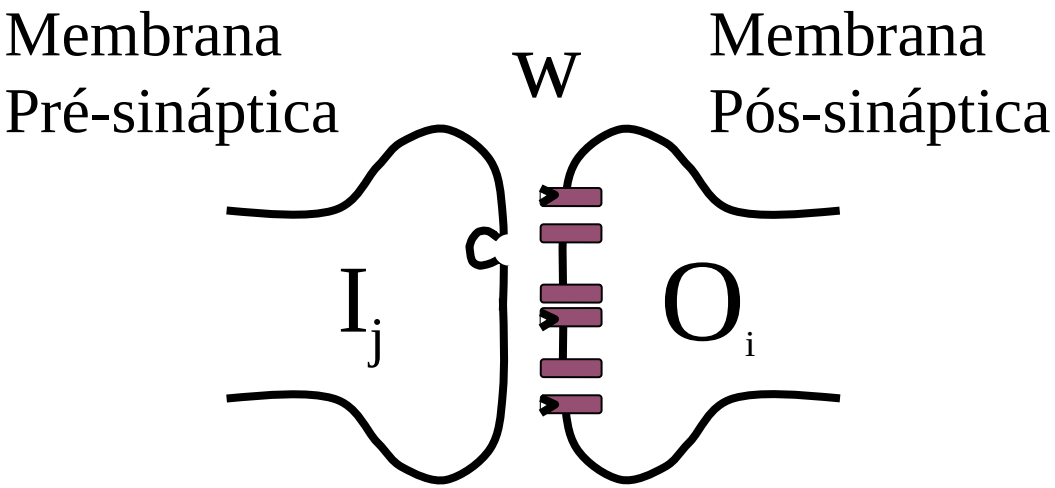

Fator de aprendizado

$$\Delta w_{ij} = \xi O_i I_j$$

$$\xi = 0{,}1$$

w_{ij}	I_j	O_i	Δw_{ij}
0	1	1	0,1
0,1	1	0,5	0,05
0,15	0,1	0,5	0,005
0,155	1	1	

Neste exemplo colocam-se valores arbitrários de I_j e Oi em cada instante

Modelos artificiais de plasticidade sináptica

1. Modelo de Hebb

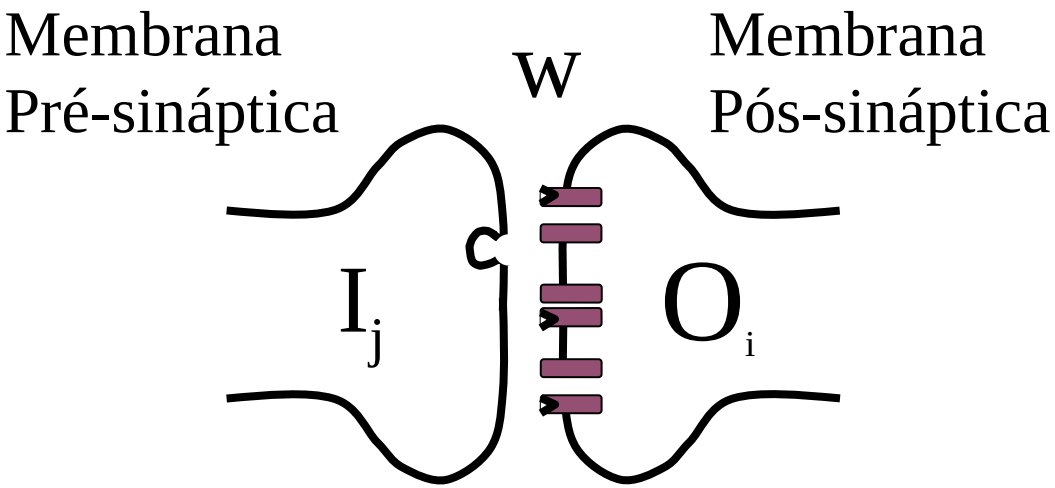

Fator de aprendizado

$$\Delta w_{ij} = \xi O_i I_j$$

$$\xi = 0{,}1$$

w_{ij}	I_j	O_i	Δw_{ij}
0	1	1	0,1
0,1	1	0,5	0,05
0,15	0,1	0,5	0,005
0,155	1	1	0,1
0,255			

Neste exemplo colocam-se valores arbitrários de I_j e Oi em cada instante

O problema mais importante da regra clássica de aprendizado Hebbiano clássico é que os pesos somente aumentam. As seguintes regras conseguem resolver o problema:

2. Regra de aprendizado de Oja

$$\Delta w_{ij} = \varepsilon (I_j \cdot O_i - O_i^2 w_{ij})$$

O neurônio de Oja consegue extrair os componentes principais dos vetores de entrada apresentados para o neurônio

3. Regra pós-sináptica

$$\Delta w_{ij} = \varepsilon O_i (I_j - w_{ij})$$

Segundo Grossberg e Minai esta regra é asintóticamente equivalente à seguinte regra probabilística.

$$w_{ij} = P(I_j / O_i)$$

A probabilidade condicionada de ter um disparo do neurônio no input j, I_j tendo acontecido um disparo no output O_i.

4. Regra pré-sináptica

$$\Delta w_{ij} = \varepsilon I_j (O_i - w_{ij})$$

Segundo Grossberg e Minai esta regra é asintóticamente equivalente à seguinte regra probabilística.

$$w_{ij} = P(O_i / I_j)$$

A probabilidade condicionada de ter um disparo do neurônio output O_i tendo acontecido um disparo no input j, I_j.

Redes associativas matriciais com aprendizado *Hebbiano*

Matriz de conexões

As entradas netas de cada um dos neurônios pode ser obtida assim:

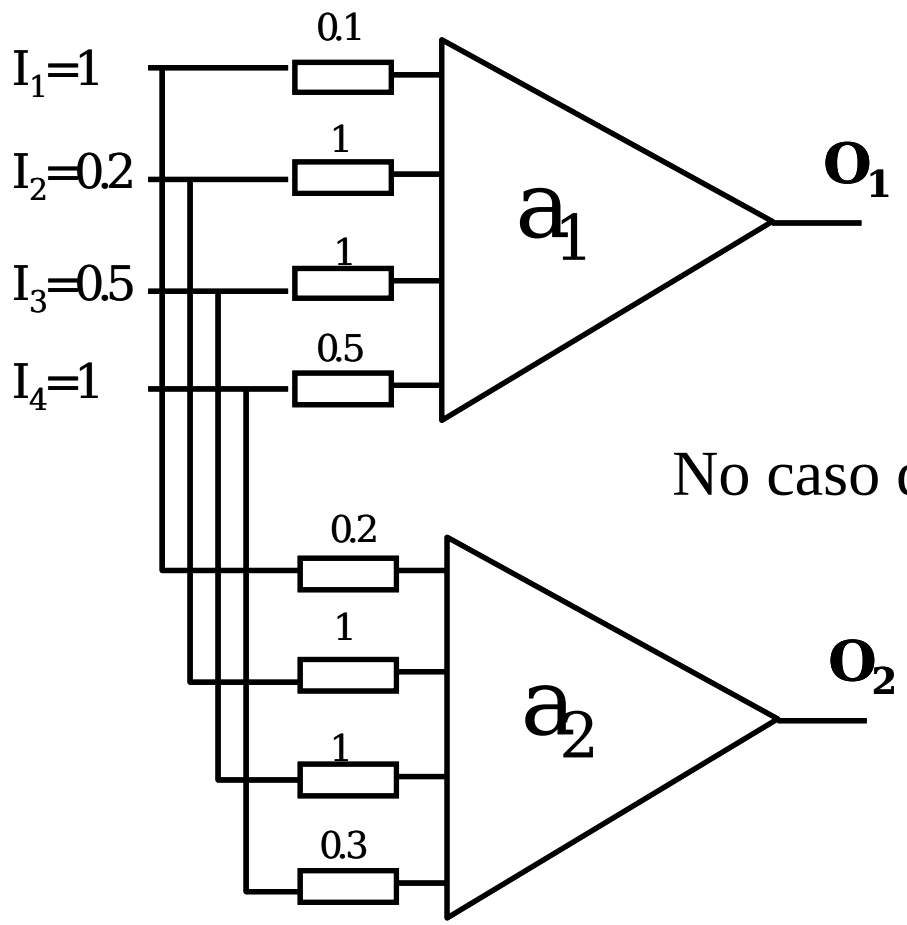

$$\begin{bmatrix} net_1 \\ net_2 \end{bmatrix} = \begin{bmatrix} w_{11} & w_{12} & \dots & w_{1j} & \dots & w_{1n} \\ w_{21} & w_{22} & \dots & w_{2j} & \dots & w_{2n} \end{bmatrix} \begin{bmatrix} I_1 \\ I_2 \\ \vdots \\ I_j \\ \vdots \\ I_n \end{bmatrix}$$

No caso da figura o resultado é:

$$\begin{bmatrix} net_1 \\ net_2 \end{bmatrix} = \begin{bmatrix} 0.1 & 1 & 1 & 0.5 \\ 0.2 & 1 & 1 & 0.3 \end{bmatrix} \begin{bmatrix} 1 \\ 0.2 \\ 0.5 \\ 1 \end{bmatrix} = \begin{bmatrix} 1.3 \\ 1.2 \end{bmatrix}$$

Matriz de conexões

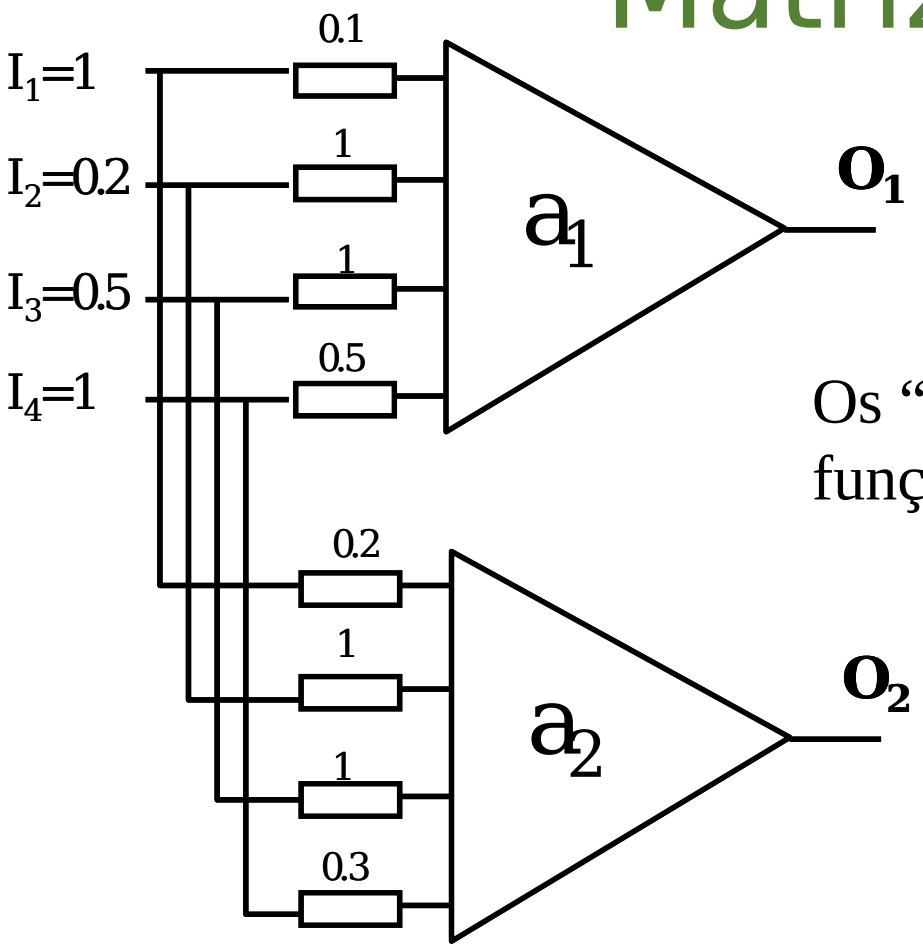

Os “outputs” são obtidos aplicando a função não linear f as ativações:

$$\begin{bmatrix} O_1 \\ O_2 \end{bmatrix} = f \begin{bmatrix} net_1 \\ net_2 \end{bmatrix}$$

Cálculo da matriz de pesos das redes associativas matriciais usando aprendizado *Hebbiano*

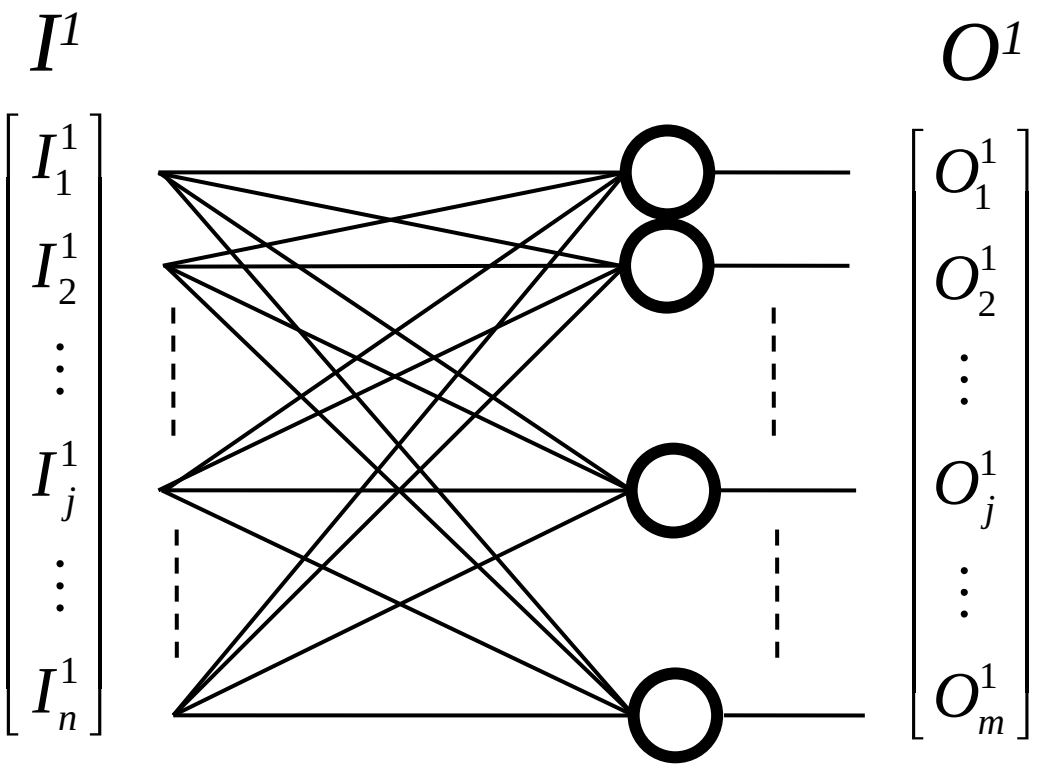
I^1
I_1^1
I_2^1
I_j^1
I_n^1
O^1
O_1^1
O_2^1
O_j^1
O_m^1

$$
I^3 \quad I^2 \quad I^1 \qquad\qquad O^3 \quad O^2 \quad O^1
$$

$$
\begin{bmatrix} I_1^3 \\ I_2^3 \\ \vdots \\ I_j^3 \\ \vdots \\ I_n^3 \end{bmatrix}
\begin{bmatrix} I_1^2 \\ I_2^2 \\ \vdots \\ I_j^2 \\ \vdots \\ I_n^2 \end{bmatrix}
\begin{bmatrix} I_1^1 \\ I_2^1 \\ \vdots \\ I_j^1 \\ \vdots \\ I_n^1 \end{bmatrix}
$$

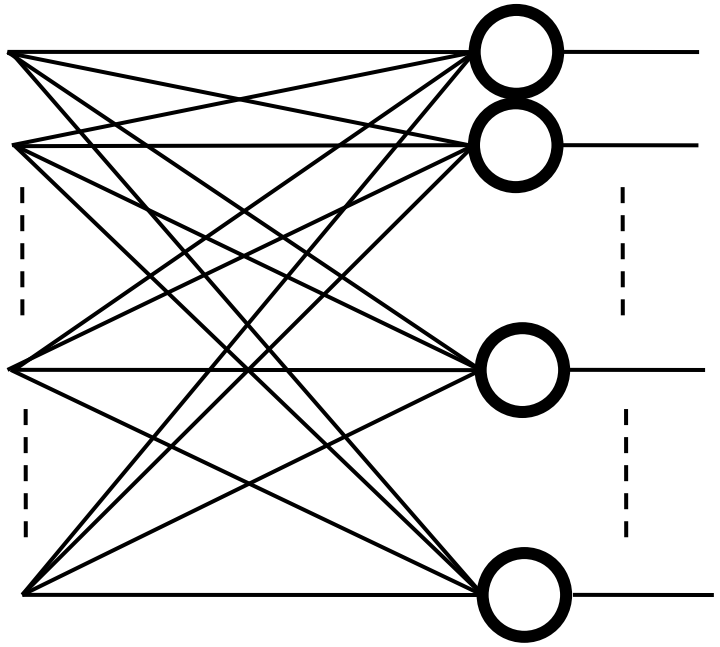

$$
\begin{bmatrix} O_1^3 \\ O_2^3 \\ \vdots \\ O_j^3 \\ \vdots \\ O_m^3 \end{bmatrix}
\begin{bmatrix} O_1^2 \\ O_2^2 \\ \vdots \\ O_j^2 \\ \vdots \\ O_m^2 \end{bmatrix}
\begin{bmatrix} O_1^1 \\ O_2^1 \\ \vdots \\ O_j^1 \\ \vdots \\ O_m^1 \end{bmatrix}
$$

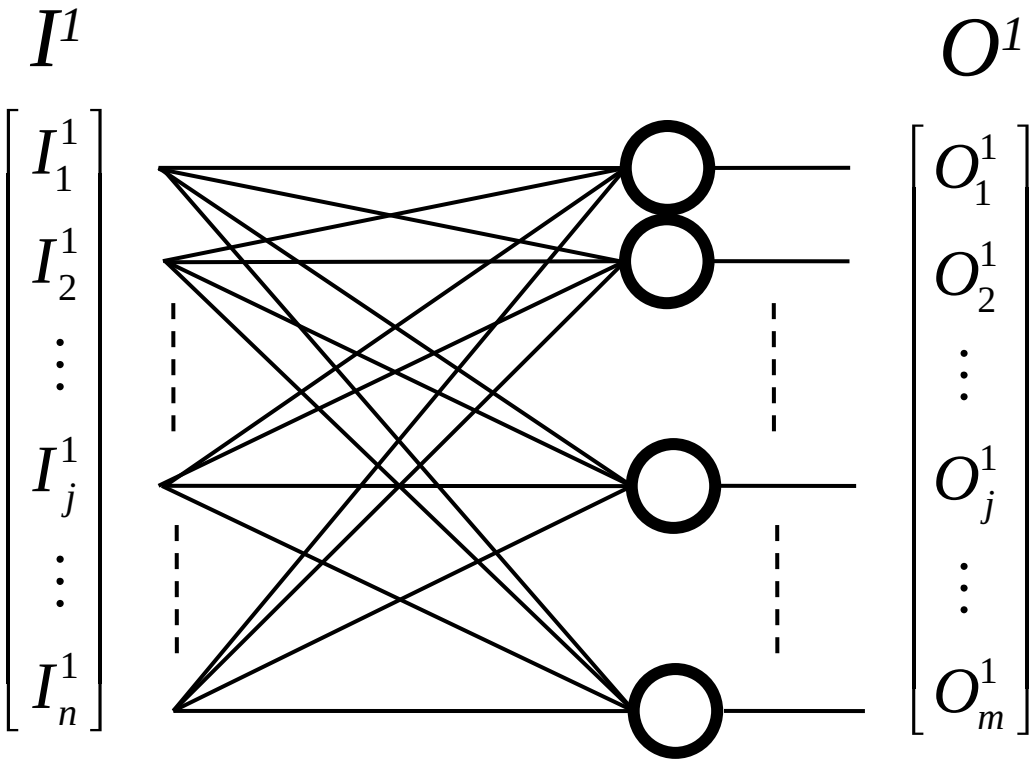
I^1
I_1^1
I_2^1
I_j^1
I_n^1
O^1
O_1^1
O_2^1
O_j^1
O_m^1

$$\Delta W^1 = \xi \cdot O^1 \cdot I^{1T} = \xi \cdot \begin{bmatrix} O_1^1 \\ O_2^1 \\ \vdots \\ O_n^1 \end{bmatrix} [I_1^1, I_2^1, \cdots\cdots, I_m^1] =$$

$$= \begin{bmatrix} \xi \cdot O_1^1 I_1^1 & \xi \cdot O_1^1 I_2^1 \cdots \xi \cdot O_1^1 I_m^1 \\ \xi \cdot O_2^1 I_1^1 & \xi \cdot O_2^1 I_2^1 \cdots \xi \cdot O_2^1 I_m^1 \\ \vdots & \vdots \\ \xi \cdot O_n^1 I_1^1 & \xi \cdot O_n^1 I_2^1 \cdots \xi \cdot O_1^1 I_m^1 \end{bmatrix}$$

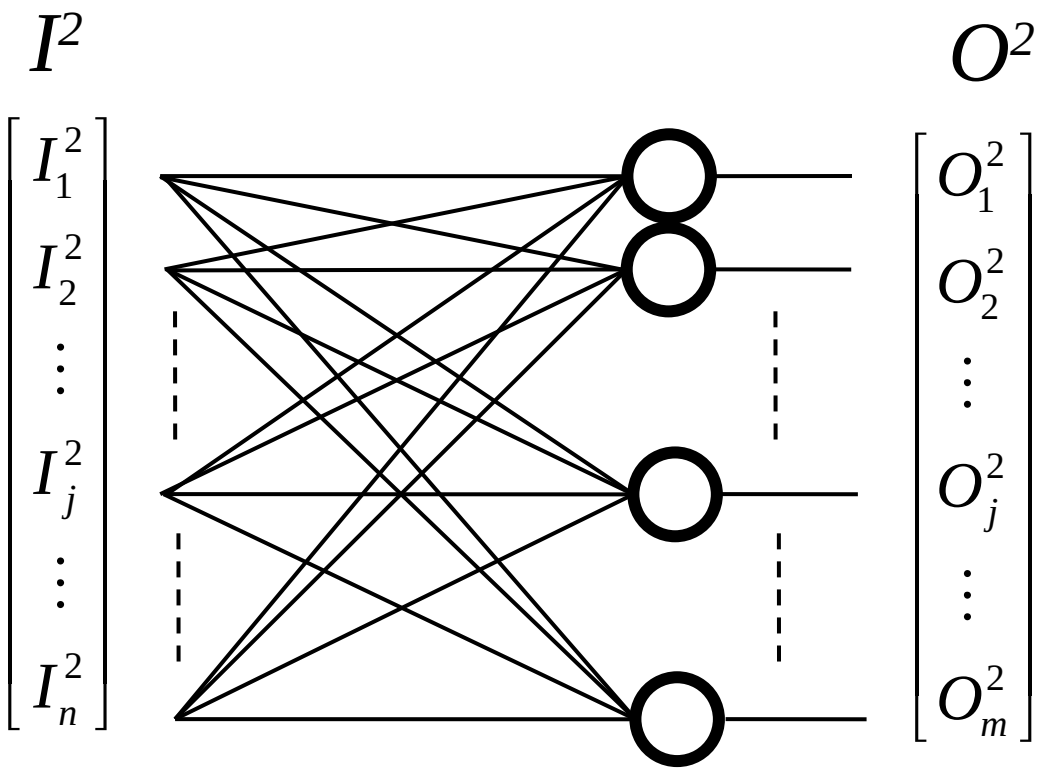
I^2
O^2
I_1^2
I_2^2
I_j^2
I_n^2
O_1^2
O_2^2
O_j^2
O_m^2

$$\Delta W^2 = \xi \cdot O^2 \cdot I^{2T} = \xi \cdot \begin{bmatrix} O_1^2 \\ O_2^2 \\ \vdots \\ O_n^2 \end{bmatrix} [I_1^2, I_2^2, \cdots\cdots, I_m^2] =$$

$$= \begin{bmatrix} \xi \cdot O_1^2 I_1^2 & \xi \cdot O_1^2 I_2^2 \cdots & \cdot \xi \cdot O_1^2 I_m^2 \\ \xi \cdot O_2^2 I_1^2 & \xi \cdot O_2^2 I_2^2 \cdots & \xi \cdot O_2^2 I_m^2 \\ \vdots & & \vdots \\ \xi \cdot O_n^2 I_1^2 & \xi \cdot O_n^2 I_2^2 \cdots & \xi \cdot O_1^2 I_m^2 \end{bmatrix}$$

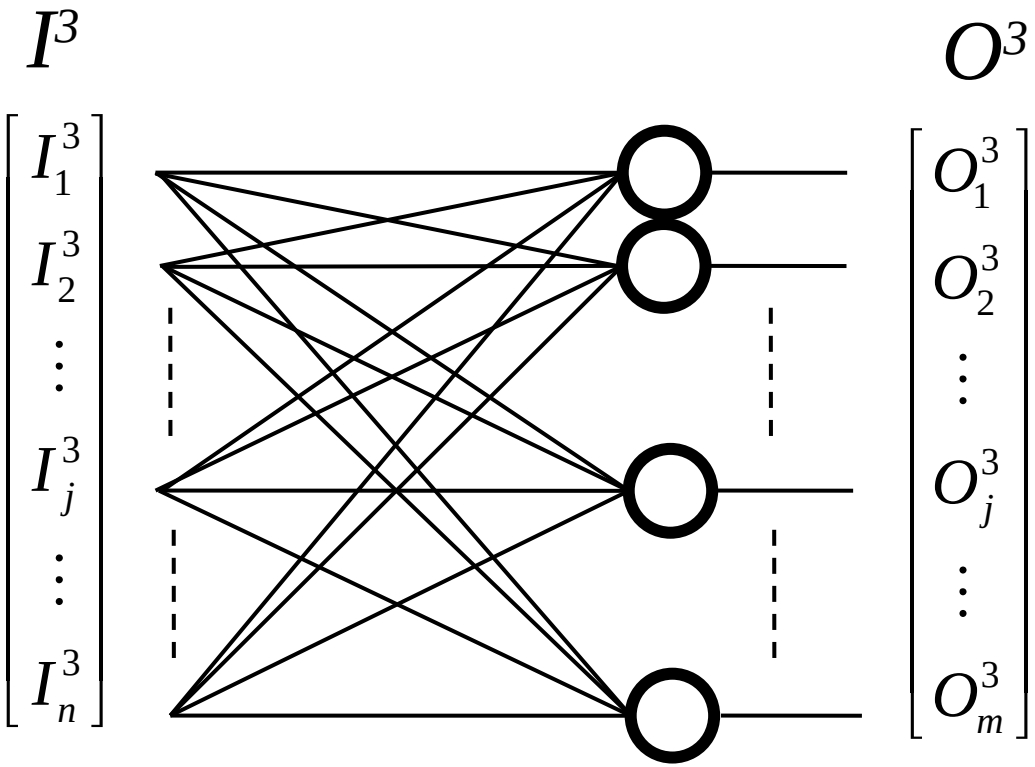
I^3
O^3
I_1^3
I_2^3
I_j^3
I_n^3
O_1^3
O_2^3
O_j^3
O_m^3

$$\Delta W^3 = \xi \cdot O^3 \cdot I^{3T} = \xi \cdot \begin{bmatrix} O_1^3 \\ O_2^3 \\ \vdots \\ O_n^3 \end{bmatrix} [I_1^3, I_2^3, \cdots\cdots, I_m^3] =$$

$$= \begin{bmatrix} \xi \cdot O_1^3 I_1^3 & \xi \cdot O_1^3 I_2^3 \cdots \xi \cdot O_1^3 I_m^3 \\ \xi \cdot O_2^3 I_1^3 & \xi \cdot O_2^3 I_2^3 \cdots \xi \cdot O_2^3 I_m^3 \\ \vdots & \vdots \\ \xi \cdot O_n^3 I_1^3 & \xi \cdot O_n^3 I_2^3 \cdots \xi \cdot O_1^3 I_m^3 \end{bmatrix}$$

$$W_{inicial} = \begin{bmatrix} O & O\cdots & O \\ O & O\cdots & O \\ \vdots & \vdots & \vdots \\ O & O\cdots & O \end{bmatrix}$$

$$W = W_{inicial} + \Delta W^1 + \Delta W^2 + \Delta W^3 =$$

$$= W_{inicial} + \xi O^1 I^{1T} + \xi O^2 I^{2T} + \xi O^3 I^{3T}$$

$$W = W_{inicial} + \Delta W^1 + \Delta W^2 + \Delta W^3 =$$

$$= W_{inicial} + \xi O^1 I^{1T} + \xi O^2 I^{2T} + \xi O^3 I^{3T} =$$

$$= 0 + \xi \begin{bmatrix} O_1^1 I_1^1 + O_1^2 I_1^2 + O_1^3 I_1^3 & O_1^1 I_2^1 + O_1^2 I_2^2 + O_1^3 I_2^3 \cdots O_1^1 I_m^1 + O_1^2 I_m^2 + O_1^3 I_m^3 \\ O_2^1 I_1^1 + O_2^2 I_1^2 + O_2^3 I_1^3 & O_2^1 I_2^1 + O_2^2 I_2^2 + O_2^3 I_2^3 \cdots O_2^1 I_m^1 + O_2^2 I_m^2 + O_2^3 I_m^3 \\ \vdots & \vdots \\ O_n^1 I_1^1 + O_n^2 I_1^2 + O_n^3 I_1^3 & O_n^1 I_2^1 + O_n^2 I_2^2 + O_n^3 I_2^3 \cdots O_1^1 I_m^1 + O_1^2 I_m^2 + O_1^3 I_m^3 \end{bmatrix}$$

$$W = W_{inicial} + \Delta W^1 + \Delta W^2 + \Delta W^3 = W_{inicial} + \xi O^1 I^{1T} + \xi O^2 I^{2T} + \xi O^3 I^{3T} =$$

$$= 0 + \xi \begin{bmatrix} O_1^1 I_1^1 + O_1^2 I_1^2 + O_1^3 I_1^3 & O_1^1 I_2^1 + O_1^2 I_2^2 + O_1^3 I_2^3 \cdots O_1^1 I_m^1 + O_1^2 I_m^2 + O_1^3 I_m^3 \\ O_2^1 I_1^1 + O_2^2 I_1^2 + O_2^3 I_1^3 & O_2^1 I_2^1 + O_2^2 I_2^2 + O_2^3 I_2^3 \cdots O_2^1 I_m^1 + O_2^2 I_m^2 + O_2^3 I_m^3 \\ \vdots & \vdots \\ O_n^1 I_1^1 + O_n^2 I_1^2 + O_n^3 I_1^3 & O_n^1 I_2^1 + O_n^2 I_2^2 + O_n^3 I_2^3 \cdots O_n^1 I_m^1 + O_n^2 I_m^2 + O_n^3 I_m^3 \end{bmatrix} = \xi \begin{bmatrix} O_1^1 & O_1^2 & O_1^3 \\ O_2^1 & O_2^2 & O_2^3 \\ \vdots & \vdots & \vdots \\ O_j^1 & O_j^2 & O_j^3 \\ \vdots & \vdots & \vdots \\ O_n^1 & O_n^2 & O_n^3 \end{bmatrix} \begin{bmatrix} I_1^1 & I_1^2 & I_1^3 \\ I_2^1 & I_2^2 & I_2^3 \\ \vdots & \vdots & \vdots \\ I_j^1 & I_j^2 & I_j^3 \\ \vdots & \vdots & \vdots \\ I_m^1 & I_m^2 & I_m^3 \end{bmatrix}^T =$$

$$= \xi \begin{bmatrix} O_1^1 & O_1^2 & O_1^3 \\ O_2^1 & O_2^2 & O_2^3 \\ \vdots & \vdots & \vdots \\ O_j^1 & O_j^2 & O_j^3 \\ \vdots & \vdots & \vdots \\ O_n^1 & O_n^2 & O_n^3 \end{bmatrix} \begin{bmatrix} I_1^1 & I_2^1 \cdots I_j^1 \cdots I_m^1 \\ I_1^2 & I_2^2 \cdots I_j^2 \cdots I_m^2 \\ I_1^3 & I_2^3 \cdots I_j^3 \cdots I_m^3 \end{bmatrix} = \xi \left[O^1, O^2, O^3 \right] \begin{bmatrix} I^1 \\ I^2 \\ I^3 \end{bmatrix} = \xi O I^T$$

$$W = W_{inicial} + OI^T \qquad W_{inicial} = \left[0\right]$$

$$W = OI^T$$

Testando a rede de memoria matricial colocando um padrão genérico, *I**, na entrada da rede.

$$O^* = f(WI^*) = WI^*$$

$$O^* = f(WI^*) = WI^* = \xi O I^T I^*$$

$$O^* = f(WI^*) = WI^* = \xi O I^T I^* =$$

$$= \xi O \begin{bmatrix} I^{1T} \\ I^{2T} \\ \vdots \\ I^{pT} \end{bmatrix} I^* = \xi O \begin{bmatrix} I_1^1 \; I_2^1 \cdots I_n^1 \\ I_1^2 \; I_2^2 \cdots I_n^2 \\ \vdots \\ I_1^p \; I_2^p \cdots I_n^p \end{bmatrix} \begin{bmatrix} I_1^* \\ I_2^* \\ \vdots \\ I_n^* \end{bmatrix}$$

$$O^* = f(WI^*) = WI^* = \xi O I^t I^* =$$

$$= \xi O \begin{bmatrix} I^{1T} \\ I^{2T} \\ \vdots \\ I^{pT} \end{bmatrix} I^* = \xi O \begin{bmatrix} I_1^1 \; I_2^1 \cdots I_n^1 \\ I_1^2 \; I_2^2 \cdots I_n^2 \\ \vdots \\ I_1^p \; I_2^p \cdots I_n^p \end{bmatrix} \begin{bmatrix} I_1^* \\ I_2^* \\ \vdots \\ I_n^* \end{bmatrix} = \xi O \begin{bmatrix} I^1 \cdot I^* \\ I^2 \cdot I^* \\ \vdots \\ I^p \cdot I^* \end{bmatrix} =$$

$$= \xi \left[O^1 \; O^2 \cdots O^p \right] \begin{bmatrix} I^1 \cdot I^* \\ I^2 \cdot I^* \\ \vdots \\ I^p \cdot I^* \end{bmatrix}$$

$$O^* = f(WI^*) = WI^* = \xi O I^t I^* =$$

$$= \xi O \begin{bmatrix} I^{1T} \\ I^{2T} \\ \vdots \\ I^{pT} \end{bmatrix} I^* = \xi O \begin{bmatrix} I_1^1 & I_2^1 & \cdots & I_n^1 \\ I_1^2 & I_2^2 & \cdots & I_n^2 \\ \vdots & & & \\ I_1^p & I_2^p & \cdots & I_n^p \end{bmatrix} \begin{bmatrix} I_1^* \\ I_2^* \\ \vdots \\ I_n^* \end{bmatrix} = \xi O \begin{bmatrix} I^1 \cdot I^* \\ I^2 \cdot I^* \\ \vdots \\ I^p \cdot I^* \end{bmatrix} =$$

$$= \xi \begin{bmatrix} O^1 & O^2 & \cdots & O^p \end{bmatrix} \begin{bmatrix} I^1 \cdot I^* \\ I^2 \cdot I^* \\ \vdots \\ I^p \cdot I^* \end{bmatrix} =$$

$$= \xi \left(I^1 \cdot I^* \right) O^1 + \xi \left(I^2 \cdot I^* \right) O^2 + \cdots + \xi \left(I^p \cdot I^* \right) O^p$$

$$O^* = f(WI^*) = WI^* =$$

$$= \xi\left(I^1 \cdot I^*\right)O^1 + \xi\left(I^2 \cdot I^*\right)O^2 + \cdots + \xi\left(I^p \cdot I^*\right)O^p$$

$$O^* = f(WI^*) = WI^* =$$

$$= \xi\left(I^1 \cdot I^*\right)O^1 + \xi\left(I^2 \cdot I^*\right)O^2 + \cdots + \xi\left(I^p \cdot I^*\right)O^p =$$

$$= \xi\left|I^1\right|\left|I^*\right|\cos\left(I^1, I^*\right)O^1 + \xi\left|I^2\right|\left|I^*\right|\cos\left(I^2, I^*\right)O^2 + \cdots + \xi\left|I^p\right|\left|I^*\right|\cos\left(I^p, I^*\right)O^p$$

- *A resposta a um padrão novo I* é uma mistura das respostas desejadas O^i aos padrões de entrada I^i.*
- *Quando todos os padrões de entrada usados no treino são ortogonais entre eles, a resposta O*a um dos padrões de entrada $I^*=I^i$ é igual a um fator multiplicado pelo vetor O^i, que era o vetor de saída desejado durante o treino para a entrada I^i. Ou seja a saída é um vetor proporcional a saída O^i desejada.*
- *Quando o padrão de teste novo é uma combinação linear $I^*=k_iI^i+k_jI^j$ e os vetores de entrada durante o treino são ortonormais, o output é $O^*=x(k_iO^i+k_jO^j)$ sendo O^i e o O^j as saídas desejadas durante o treino da rede para as entradas I^i e I^j.*

Lei fundamental do aprendizado Hebbiano

- Para que uma rede de tipo associativo consiga associar um conjunto de padrões de entrada com um conjunto de padrões de saída sem acontecer interferências, os padrões de entrada I^i, precisam ser **ortogonais**.

Função de atenção do chatGPT

(ou: Me diga com quem você anda e lhe direi quem você é)

$$\mathrm{Attention}(Q, K, V) = \mathrm{softmax}(\frac{QK^T}{\sqrt{d_k}})V$$

Na computação usam-se vetores linhas então, as matrizes Q,K e V são matrizes usando vetores linha.

Exercício: Transpor a seguinte equação que vimos antes e que usa vetores coluna. Após a transposição substituir: $K=I^T$; $V=O^T$; $Q=I^{*T}$

$$O^* = f(WI^*) = WI^* = \xi OI^T I^*$$

Na computação usam-se vetores linhas.

Exercício: Na equação seguinte que já vimos antes supor que os vetores de O e I são iguais e normalizados. Se o I* for um dos vetores de I, por exemplo I^1, calcular como é alterado este vetor por causa dos seus demais vizinhos $I^1, I^2, \ldots I^p$

$$O^* = f(WI^*) = WI^* =$$

$$= \xi\left(I^1 \cdot I^*\right)O^1 + \xi\left(I^2 \cdot I^*\right)O^2 + \cdots + \xi\left(I^p \cdot I^*\right)O^p =$$

$$= \xi\left|I^1\right|\left|I^*\right|\cos\left(I^1, I^*\right)O^1 + \xi\left|I^2\right|\left|I^*\right|\cos\left(I^2, I^*\right)O^2 + \cdots + \xi\left|I^p\right|\left|I^*\right|\cos\left(I^p, I^*\right)O^p$$

Attention

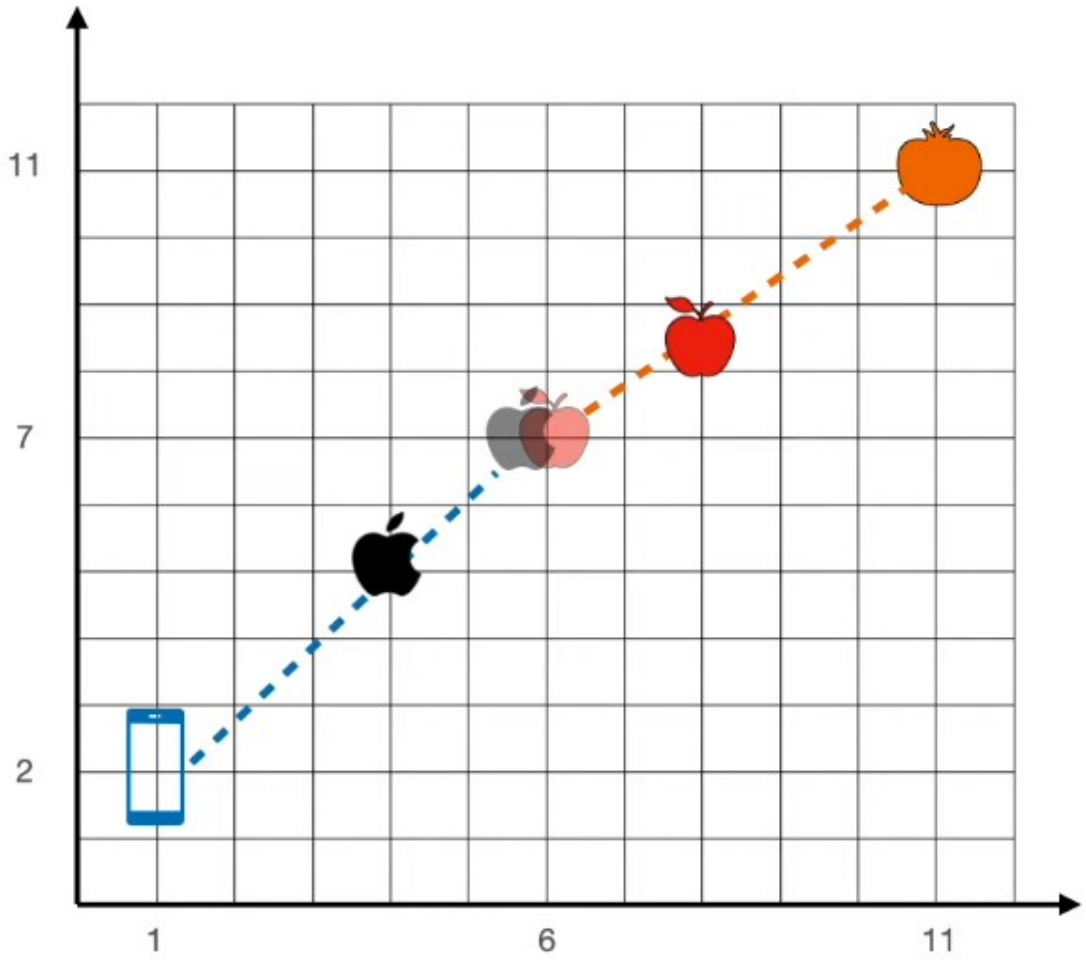

please buy an apple and an orange
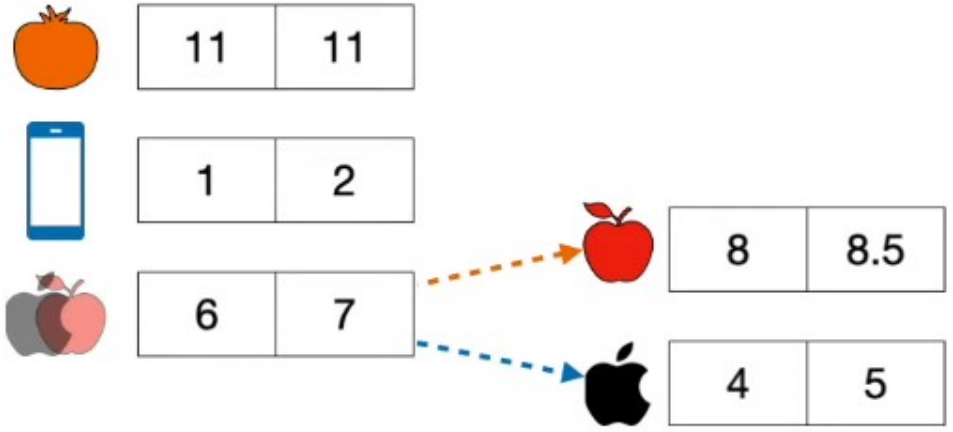
apple unveiled the new phone